



Kick-Off Ruban Rose





Classification Histopathologique du Cancer du Sein

Classification d'images



BHI = Dataset du sujet (recommandé pour le projet) :

- <https://drive.google.com/file/d/14hTFPJ2AhhgVtOXGHMjTzSGR4EvnK5AB/edit>
- ou <https://www.kaggle.com/datasets/aminbhuyan/breast-histopathology-images>

BreakHis = Dataset du Kickoff :

- <https://www.kaggle.com/datasets/ambarish/breakhis>

L'IA pour le diagnostic du cancer du sein

Un diagnostic tardif réduit la survie à 5 ans de ~99 % à ~27 %.



Enjeu clinique majeur

2^{ème} cause de décès par cancer chez la femme.

En 2024, **2,3 millions** de nouveaux cas.

Diagnostic fastidieux / analyse microscopique
de biopsies



Valeur ajoutée de l'IA

Réduire le temps de lecture de **40 à 60 %**

Diminuer faux-négatifs

Offrir un second avis objectif.



La biopsie histopathologique

Méthode de référence (gold standard) :
prélèvement tissulaire, coloration H&E, lecture
au microscope optique. La structure cellulaire
révèle la malignité.



Objectif pédagogique

Classification sur le dataset public **BreakHis**,

Comparer 4 architectures pré-entraînées

Optimiser les hyperparamètres par **Optuna**.

Dataset BreakHis – images histopathologiques

7 909

images totales • PNG 700×460

82

patients distincts

4 grossissements

40× • 100× • 200× • 400×

Répartition par classe

Bénin  **2 480 • 31%**

Malin  **5 429 • 69%**

⚠ Déséquilibre ~1:2.2 → rééquilibrage nécessaire

8 sous-types tumoraux

- | | |
|--------------------------|-----------------------------|
| ■ Adénose (A) – bénin | ■ Carcinome ductal (DC) |
| ■ Fibroadénome (F) | ■ Carcinome lobulaire (LC) |
| ■ Tumeur Phyllodes (PT) | ■ Carcinome mucineux (MC) |
| ■ Adénome tubulaire (TA) | ■ Carcinome papillaire (PC) |

Réseaux de Neurones Convolutifs (CNN)

Un CNN extrait automatiquement une **hiérarchie de caractéristiques visuelles** — des contours simples (couches basses) aux structures biologiques complexes (couches hautes) — sans ingénierie manuelle des features.

Couches Convolutionnelles

Filtres $k \times k$ glissants $\rightarrow$ feature maps $\rightarrow$ activation ReLU

Pooling (Max / Average)


Sous-échantillonnage spatial $\rightarrow$ invariance aux translations

Couches Denses + Softmax

Classification finale $\rightarrow$ probabilités de classe (Bénin / Malin)

Entraînement

Rétropropagation · Optimiseur Adam · Binary Cross-Entropy Loss



Paramètres appris par descente de gradient stochastique (SGD / Adam) sur mini-batches

Transfer Learning

Réutiliser pour mieux apprendre

Principe

Un réseau pré-entraîné sur **ImageNet (1,2 M images · 1 000 classes)** a déjà appris textures, formes et structures visuelles. On réutilise ce "savoir" et on réentraîne uniquement la tête de classification sur BreakHis.

Deux stratégies

- **Feature Extraction** : backbone gelé, seule la tête est entraînée. Rapide, peu de données nécessaires.
- **Fine-tuning** : dégel progressif des dernières couches du backbone. Meilleure adaptation au domaine médical.

4 Architectures comparées

ResNet-50

Connexions résiduelles · 50 couches · 25 M params

EfficientNet-B3

Scaling composé · 12 M params · Top efficacité


DenseNet-121

Connexions denses · 8 M params · Feature reuse

Vision Transformer (ViT)

Self-attention · Patches 16×16 · État de l'art 2024

Pipeline Méthodologique Complet



EDA

Distribution des classes,
grossissements,
visualisation
images brutes



Prétraitement

Resize 224×224,
normalisation
ImageNet, split
stratifié



Augmentation

Flips, rotations,
color jitter, Cutout



Modélisation

4 CNN
pré-entraînés +
tête de
classification
fine-tunée



Optuna

HPO : LR,
batch,
dropout,
weight
decay —
50 trials
TPE



Évaluation

AUC-ROC, F1,
Recall, matrice
confusion par
grossissement



Grad-CAM

Carte
d'activation
—
explicabilité
des
décisions

Stack Python : PyTorch · torchvision · Optuna · scikit-learn · matplotlib · seaborn · grad-cam

Métriques adaptées au contexte médical



AUC-ROC

Discriminabilité globale
bénin/malin, indépendante du seuil



Recall (Se)

Sensibilité — minimiser les faux
négatifs (cas malins manqués)



F1-Score

Compromis précision/rappel —
robuste au déséquilibre de classes

Résultats attendus — état de l'art BreakHis

ResNet-50	~90%
EfficientNet-B3	~93%
DenseNet-121	~92%
ViT (fine-tuné)	~94%

Accuracy patient-level · grossissement 40×

Précautions d'évaluation

Patient-level split :

éviter la fuite de données entre patients

K-Fold stratifié :

validation croisée sur les patients

Weighted loss / SMOTE :

compenser le déséquilibre 31/69 %

Grad-CAM :

vérifier que le réseau regarde la zone tumorale



Prêt à coder !



Étape 1

**Charger &
explorer
BreakHis**



Étape 2

**Fine-tuner 4
architectures**



Étape 3


**Optimiser via
Optuna**



Étape 4

**Évaluer &
Grad-CAM**

Des Questions ?



 La Plateforme